基于扩散模型的生成式图像检测综述

罗昊，辛一冉，唐云祁
（中国人民公安大学侦查学院，北京 100038）

摘　要： 近年来，基于扩散模型（DM）的生成式图像技术取得了突破性进展，以 Stable Diffusion、DALL-E 和 Midjourney 为代表的文生图模型已经广泛应用于商业领域和日常生活。然而，高度逼真的 AI 生成图像也带来了图像真实性挑战，催生了虚假信息传播、版权侵犯等社会问题。为有效应对这些挑战，本文系统综述了基于扩散模型的生成图像检测技术的最新研究进展。首先，梳理了扩散模型从原理、基础框架到大规模应用的发展。其次，总结数据集发展，指出数据集建设正从少量生成器、低分辨率向多模型融合、高质量多级筛选方向发展。再次，分析了检测技术的三大主流方法：基于隐式特征的检测技术、基于显式特征的检测技术以及基于混合特征的检测技术。最后，分析了当前检测技术面临的主要挑战，并展望了未来研究方向。本综述为研究人员和从业者提供了全面的技术图谱和发展趋势参考。

关键词： 扩散模型；文生图；生成图像；生成图像伪影；生成图像检测
中图分类号： TP391.41　　**文献标志码：** A　　**DOI：** 10.19678/j.issn.1000-3428.0253234

Review of Generative Image Detection Based on Diffusion Models

LUO Hao, XIN Yiran, TANG Yunqi
(School of Criminal Investigation, People's Public Security University of China, Beijing 100038, China)

【Abstract】 In recent years, generative image technology based on Diffusion Models (DMs) has made breakthroughs, with text-to-image models represented by Stable Diffusion, DALL-E, and Midjourney have been widely applied in commercial sectors and everyday life. However, highly realistic artificial intelligence-generated images have also brought challenges to image authenticity, giving rise to social issues such as the spread of misinformation and copyright infringement. To address these challenges effectively, this paper systematically reviews the latest research progress in detection technologies for images generated by DMs. First, it outlines the development trajectory of DMs based on their principles and fundamental frameworks for large-scale applications. Second, it summarizes the evolution of dataset construction, indicating that dataset development is progressing from using few generators and low resolutions to multi-model integration and high-quality, multi-stage filtering. Third, it analyzes three types of detection technologies: those based on implicit, explicit, and hybrid features. Finally, it analyzes the main challenges facing current detection technologies and provides an outlook on future research directions. This review offers researchers and practitioners with a comprehensive technical landscape and reference for future development trends.

【Key words】 Diffusion Model (DM); text-to-image; generated image; generated image artifact; generated image detection

0　引言

人工智能生成内容（AIGC）技术发展迅速，给社会工作、生活带来便利，其中扩散模型（DM）的运用让人们可以很轻易地凭借文本、声音描述来生成具有创造性的图像。基于扩散模型的生成图像技术不仅可以辅助人类进行天马行空的艺术创作，还能作为恶意工具生成违背事实的内容，加之图像作为传播信息的重要载体，引发了人们对图像内容真实性的忧虑。

基于扩散模型的生成图像技术从 2015 年提出技术理论，到 2021 年图像生成质量突破，再到 2023 年引入文本引导内容生成，现在已经广泛应用于视觉大语言模型等商业领域，深受用户好评。同时，这类技术的恶意应用也造成了诸多负面影响。2024 年 1 月，某 MCN 机构利用 AI 工具批量生成虚假地震、火灾灾难图文，在社交媒体上传播来获取流量，造成负面影响。2024 年 5 月，画师张某发现其原创作品被某商家利用 AI“融图”技术生成商品图并售卖，引发版权纠纷。2025 年 1 月，杭州某智能科技公司开发的 AI 平台允许用户上传图片并生成与奥特曼形象高度相似的作品，原告上海某文化

基金项目： 国家社会科学基金重大项目（25&ZD238）；中国人民公安大学刑事科学技术双一流创新研究项目（2023SYL06）。
作者简介： 罗昊，男，博士研究生，主研方向为生成图像检测、图像鉴定；辛一冉，博士研究生；唐云祁（通信作者），教授、博士。
收稿日期： 2025-11-03　　**修回日期：** 2026-01-14
E-mail： tangyunqi@ppsuc.edu.cn

计算机工程 www.ecice06.com

公司认为其侵犯信息网络传播权及违反《中华人民共和国反不正当竞争法》。2025 年 6 月，张某某为了获得流量，通过拼接网络上的热点要素，制作虚假视频发布，造成了极大的负面舆论影响。

面对生成图像技术的负面影响，应对虚假信息传播、个人信息侵权等问题，中国信通院于 2022 年发布《人工智能生成内容白皮书》跟踪技术发展。同时，政府部门积极规制，于 2023 年发布《生成式人工智能服务管理暂行办法》，于 2025 年发布《人工智能生成合成内容标识办法》，进一步管理生成内容。同阶段，美国、欧洲、新加坡等国也出具相关文件来应对人工智能生成内容所带来的挑战。

在基于扩散模型生成图像技术发展的同时，对应的检测反制技术也在逐步发展，为了让大家对这类反制技术有一个系统性的了解。本文首先介绍了基于扩散模型的发展，从技术理论奠基、模型重要框架建立到现在的应用发展；然后介绍了当前通用性高、独具特点的数据集；接着对扩散模型生成图像检测技术的发展进行梳理；最后对这 3 个部分进行总结与展望。

1 研究方法

近年来，基于扩散模型的生成式图像技术取得了突破性进展，高质量的图像质量和便捷的对话式操作使其成为 AIGC 领域核心架构。然而，伴随其广泛应用而来的数字内容可信性与安全挑战也日益突出，亟需建立高效、鲁棒的检测与鉴别体系。尽管当前关于扩散模型生成技术本身的综述文献数量较多，但专门针对基于扩散模型的生成图像检测技术进行系统性、前沿性梳理的文献相对匮乏，且已有的相关综述仍存在局限性：

1）时效性滞后与技术覆盖不全：文献[1]虽然阐述了基于扩散模型的滥用问题并介绍了相关检测技术，但其内容更新截至 2024 年，未能及时覆盖当前出现的前沿检测技术。

2）针对性与性能比较缺失：文献[2]的范围过于宽泛，涵盖了所有生成图像检测技术，导致其对扩散模型特有的检测机理缺乏深入剖析，且未进行相关检测技术的性能横向对比。

3）方向侧重差异：文献[3]主要从文本、图像等多模态数据的主动检测与被动防御角度，综述了人工智能生成内容的伪造内容的滥用防范问题，其关注点与本文聚焦于检测技术机理与性能分析的研究方向有所不同。

4）深度与广度不足：文献[4]虽然聚焦于扩散模型生成图像检测任务，但其对当前最新成果的覆盖度不高，且缺乏系统、严谨的横向对比分析。

鉴于上述研究的现状，本文旨在系统性地梳理和深入剖析基于扩散模型的生成图像检测技术的最新进展，涵盖从隐式特征、显式特征到混合特征三大主流检测范式，并着重对各类技术进行横向性能比较，以期为研究人员和从业者提供一个涵盖核心检测机理、技术性能对比和未来发展趋势的全面技术图谱。本文梳理已在各类权威期刊和会议上发表、用于生成图像检测技术的文献。用于本次回顾的具体方法与技术流程如表 1 所示。

表 1 文献收集与准备流程

Table 1 Literature collection and preparation process

Preparation	Description
Purpose	1. Briefly summarize the existing generative image technologies based on DMs and conduct a horizontal comparison of them; 2. Systematically sort out and summarize the existing generative image detection technologies based on DMs
Data sources	Google Scholar, Springer, ACM, IEEE Xplore, DBLP, arXiv and CNKI
Query	Diffusion-generated image limited to review("generated image detect" OR "synthetic image detect" OR "forgery image detect" OR " fake image detect")NOT("deepfake"); The search time frame for the above-mentioned literature is limited to 2022 to the present
Methods	In terms of DM-generated images, this paper is divided into two sections: the principles and frameworks of DMs, and the breakthroughs in DMs; In terms of detection technologies for DM-generated images, this paper is divided into three sections: implicit feature-based detection technologies, explicit feature-based detection technologies, and hybrid feature-based detection technologies
Sizes	As of November 26, 2025, we have screened a total of 145 papers using the aforementioned methods and search criteria; Among them, we selected papers whose themes are more relevant to the scope of "DM-generated images"
Study	We focus more on peer-reviewed journal papers and conference papers; in addition, we also pay attention to some representative papers from DBLP and arXiv

计算机工程 www.ecice.com

下面将结合 PRISMA 流程具体介绍文献梳理流程，如图 1 所示（彩色效果见《计算机工程》官网 HTML 版，下同）。本文使用表 1 中的查询关键词在数据库和注册库中查询到 361 篇文献，通过关注会议网页查询到文献 94 篇。通过时间限定，重复文献筛查、人工筛查等操作，去除与目标差距过大的文献。

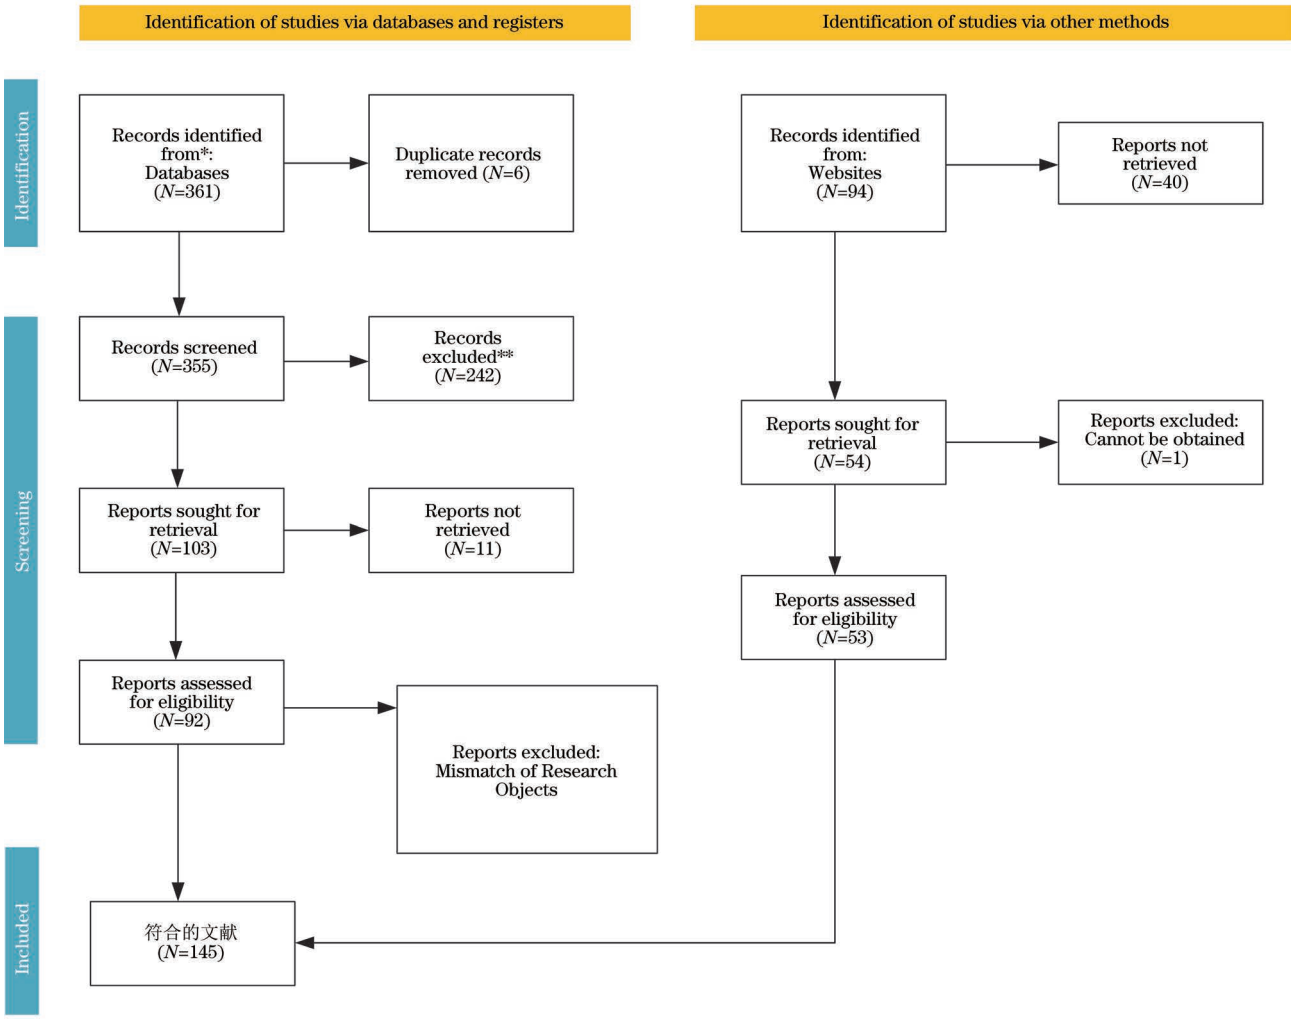


图 1 PRISMA 流程

Fig. 1 PRISMA flow

2 扩散模型生成式图像技术原理与发展

扩散模型已经成为各大生成图像商业软件的主流算法。其核心的技术是通过参数学习增加噪声去除图像的语义特征，然后逆向求解去噪，在恢复图像语义的同时产生新的内容。本节首先介绍扩散模型理论奠基，然后汇总当前扩散模型的实用突破和大规模应用创新。

2.1 扩散模型原理与框架

受非平衡物理学的启发，文献[5]提出了扩散概率模型这一系统性理论框架。该框架通过一个明确的前向扩散过程（逐步添加噪声）和一个可学习的反向生成过程（逐步去除噪声）来训练生成模型，为扩散模型在图像生成领域的应用奠定了基础。这一算法框架凭借迭代学习的方法，在生成简单的二值序列、手写体数字、CIFAR-10（32×32 像素）自然图像和树皮纹理的场景中取得了一定的效果，并且实现了一些简单的图像修复工作[5]。

在此基础上，降噪概率扩散模型（DDPM）[6]简化了图像扩散生成的步骤，不仅大幅提升了图像生成的质量与效率，还推动了扩散模型理论的进一步完善与普及，提出了现代扩散模型的标准框架。其主要的步骤可以总结为前向过程和反向过程，如图 2 所示，其中，第一行为图像逐步增加噪声的过程，第二行为图像逐步去噪的生成过程。

扩散模型的前向过程是由数据分布 X_0 在时间步长 T 中逐步增加高斯噪声，将原始数据分布 $q(x_0)$ 转化为易于采样的高斯分布 $q(x_T)\sim\mathcal{N}(0,I)$，其转移核为：

$$q(x_t|x_{t-1})=\mathcal{N}(x_t;\sqrt{1-\beta_t}x_{t-1},\beta_t I) \tag{1}$$

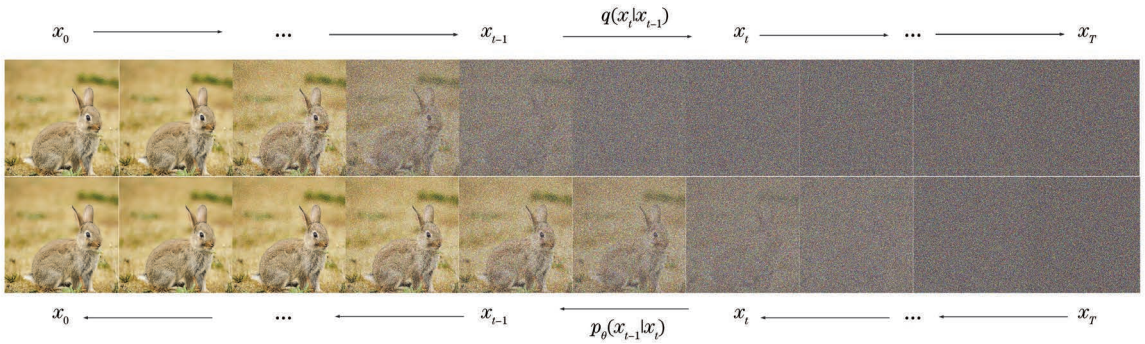


图 2 降噪扩散模型图像生成过程

Fig. 2 Image generation process of denoising DMs

前向过程的联合分布可分解为多个转移核的乘积：

$$q(x_{1:T}|x_0)=\prod_{t=1}^{T}q(x_t|x_{t-1}) \tag{2}$$

通过上述步骤，就可以从 X_0 中直接得到 X_t。

$$x_t=\sqrt{\bar{\alpha}_t}x_0+\sqrt{1-\bar{\alpha}_t}\varepsilon,\varepsilon\sim\mathcal{N}(0,I) \tag{3}$$

扩散模型的反向过程是通过参数化的马尔可夫链逐步降噪，生成符合原始数据分布 $q(x_0)$ 的样本 X_0。这个反向过程的每一步为参数化的高斯分布：

$$p_\theta(x_{t-1}|x_t)=\mathcal{N}\left(x_{t-1};\mu_\theta(x_t,t),\sum_\theta(x_t,t)\right) \tag{4}$$

式中：$\mu_\theta(x_t,t)$ 和 $\sum_\theta(x_t,t)$ 由深度神经网络预测，学习目标是逼近正向过程的逆过程 $p_\theta(x_{t-1}|x_t)$。

文献[7]将扩散模型和基于分数的模型用 SDE 统一表示，进一步完善了扩散模型的理论。为了提高模型的采样效率，降噪扩散隐式模型(DDIM)[8]将采样步数从千步降到数十步。文献[9]进一步改进了采样过程中的噪声调度和模型架构，使得生成图像质量进一步提升。在此基础上，消融扩散模型(ADM)[10]通过细致的架构消融研究确立了高性能的 U-Net 架构[11]标准，并引入了分类器引导这一强大机制，为扩散模型提供了可控的保真度和多样性权衡能力。该文通过对比扩散模型与生成对抗网络(GAN)的图像生成能力，指出扩散模型在 ImageNet 上超越了 GAN，证明了扩散模型的潜力。

隐扩散模型(LDM)[12]如图 3 所示，使用通用数据集提前训练编码器E与解码器D，将图像从像素空间映射至潜在向量空间，让特征 Z 在潜在向量空间经过噪声的增减变换，使得计算效率取得了关键性突破，为扩散模型后续的大规模应用奠定了基础。

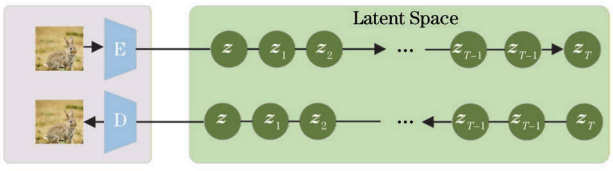


图 3 LDM 图像生成过程

Fig. 3 Image generation process of LDM

2.2 扩散模型突破

在基础理论和架构的支持下，结合多类大规模数据集，扩散模型在图像生成领域得到了广泛且大规模的应用，在多类图像处理任务中获得优异表现，并催生了以文本为导向的图像生成、视频生成及 3D 生成等多模态生成的热潮。

基础的扩散模型聚焦于海量学习图像数据分布，通过去除噪声来生成一张类似真实的图像，这一行为也被称为无条件生成。为了实现真正可控的图像生成，在 ADM 架构的基础上，GLIDE[13]在图像的生成过程中加入了无分类器引导文本策略，先生成低分辨率图像，再使用上采样模型生成高分辨率图像(如图 4 所示)，这证明了扩散模型在有条件生成任务上的潜力。随后，CHITWAN 等[14]结合大语言模型和扩散模型，在文本约束的条件下，使生成图像质量进一步提升。HO 等[15]提出无需额外分类器的条件生成方法，成为文生图的标准控制方法。

此外，扩散模型凭借独特的语义理解与记忆能力，在图像编辑[16]、去模糊[17]、超分辨率[18]、图像修复[19]和基于参考图像的生成[20]等任务中取得了优异的表现。

大规模的商业应用使得扩散模型得到了进一步的推广。OpenAI 公司使用大规模数据集，结合 CLIP 模型将文本特征与图像特征对齐，提出 DALL-E2 模型[21]。DALL-E2 的推出让人们第一次熟知通过文本描述可以直接生成创造性的图像。基于隐空间扩散技术的 Stable Diffusion(简称为 SD)开源其技术框架，使得大量用户涌入，并产生了大量的生成图像模板，Midjourney(简称为 MJ)社区进一步激发了人们对生成图像的创作热情，同时谷歌提出了 Imagen，促进了高质量商业图像的生成。

计算机工程 www.ecice.com

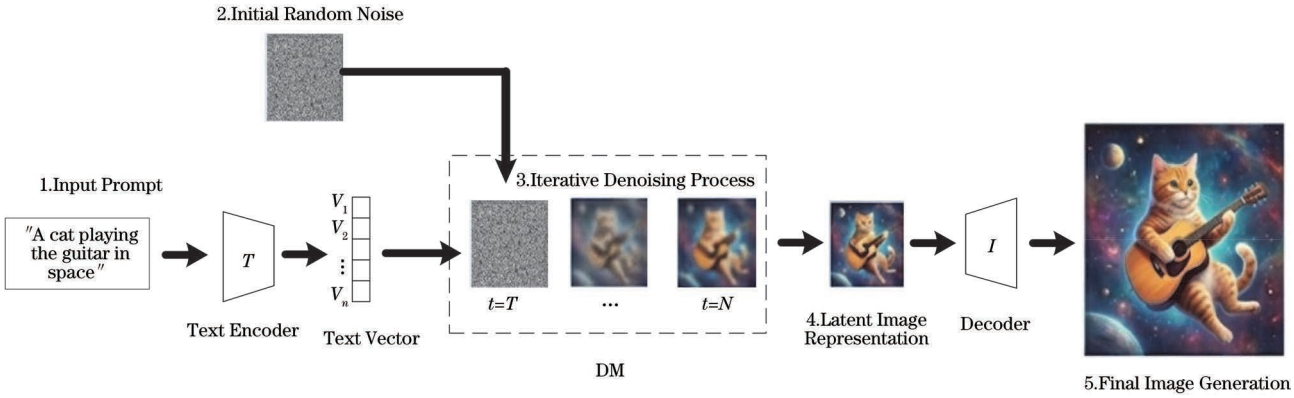


图 4 文生图技术路径展示

Fig. 4 Demonstration of the technical path for text-to-image generation

在此基础上，各大商业公司不断推动相关软件的产品迭代，通过精确的空间控制、轻量化控制模块及知识蒸馏加速技术，并结合单步生成与多功能模块融合等手段，显著加速了图像生成技术的商业化落地进程。

3 数据集与检测技术性能评估

3.1 数据集

早期方法的训练数据集中的真实图像与生成图像存在分辨率、格式、语义内容等差异，导致检测模型偏向虚假特征（如 JPEG 压缩痕迹或图像大小），而非本质伪影。近年来，很多研究强调通过对齐真实与生成图像的分布，迫使模型聚焦于生成模型引入的固有伪影，从而改善跨模型和跨场景的检测性能。

GROMMELT 等[22]探讨了 GenImage 数据集[23]中 JPEG 压缩的问题，并对齐了真伪图像的数据格式。RAJAN 等[24]指出，简单的变分自编码器（VAE）重建即可高效生成与真实图像在语义和分辨率上高度对齐的伪造样本，从而消除尺寸调整等预处理带来的偏差。在此基础上，GUILLARO 等[25]提出的 B-Free 范式进一步引入了自条件生成和内容修复增强，确保了真伪样本在语义内容上的严格一致性，迫使检测器专注于生成器引入的细微伪影。CHEN 等[26]提出的双重数据对齐（DDA）对此进行了修正，通过在 VAE 重建的基础上融合真实图像的高频信息并进行像素混合，实现了像素与频率域的双重对齐，有效防止了模型对频率伪影的过拟合。不同于上述在训练阶段进行对齐的方法，WANG 等[27]提出的 PDA 采用了一种测试时的后验分布对齐策略，通过将测试图像“重生成”为已知生成模型的伪样本，使真实图像的重生成版本与已知伪造分布对齐，从而利用 k-NN 距离区分分布偏离较大的未知伪造图像，无需重新训练即可适应新模型。

数据集对齐已经从单纯的像素统计特性演进到了高层的语义逻辑一致性，通过多维度的对齐约束，使得检测器捕捉生成过程本质的缺陷而非表面偏差，也为专用检测器提供了更有利的支撑。下面对一些比较典型的数据集进行介绍：

GenImage[23]：该数据集的真实图像源于 ImageNet[28]，生成图像源于 BigGAN[29]、GLIDE[13]、VQDM[30]、SDv1.4[12]、SDv1.5[12]、ADM[10]、MJ、WuKong 8 类生成器，参照 ImageNet 中 1 000 个分类的标签，覆盖多场景和目标，后续多类检测算法将其作为通用检测数据集。

DiffusionForensics[31]：该数据集使用 ADM[10]、DDPM[6]、iDDPM[9]、PNDM[32] 4 个生成模型生成的图像用于构建训练集与验证集，使用 LDM[12]、SDv1[12]、SDv2[12]、VQDM[30] 生成的图像作为测试集。

UniversalFakeDetect[33]：该数据集选用了多类生成模型，包括 ProGAN[34]、StyleGAN[35]、BigGAN[29]、CycleGAN[36]、StarGAN[37]、GauGAN[38]、CRN[39]、IMLE[40]、SAN[41]、ITD[42]、DeepFakes[43]、LDM[12]、GLIDE[13] 和 DALL-E。其中 LDM 和 GLIDE 模型采用了 3 种去噪步数来生成图像，展现了同类生成模型的不同状态，成为多种真伪图像分类方法的检测数据集。

DiffusionFace[44]：该数据集聚焦于多类扩散模型在人脸伪造场景中的应用，使用无条件、文本引导、图像＋文本引导、面容局部修改、换脸操作 5 种人脸图像修改方式生成图像。

Fake2M[45]：该数据集集合了扩散模型、对抗神经网络和自回归（AR）模型，一共分为两个部分：第一部分使用 MJv5，通过多个维度的真实性提示词约束，生成高质量的现实场景图像，供人工分辨真伪

图像;第二部分使用 11 类生成模型,包括多类不同版本的生成模型,供不同分类器模型训练测试真伪图像检测性能。

SynthScars[46]:该数据集汇集 RichHF-18K[47]、Chameleon[48]、FFAA[49]数据集的生成图像,使用 ResNet-50[50]对潜在特征进行聚类,确保数据集的多样性和平衡性,使用 Qwen2-VL-72B-Instruct[51]大语言模型多阶段筛选低质量生成图像,最后由专业的标注人员对图像中的生成伪影进行像素级的不规则多边形掩码标注,并提供详细的文本描述和伪影类型标签。

SID-Set[52]:该数据集包含 10 万张来自 OpenImages V7 数据集的真实图像,每张图像包括了图像语义级别的标签、目标框、目标分割掩码、目标视觉关系和定位描述。使用 FLUX 生成 10 万张高质量的仿真图像。使用 LDM 模型对图像进行目标替换(8 万张图像)和局部替换(2 万张图像),并使用 GPT-4o 生成 3 000 张生成图像的文本描述用于后续分类器判断生成伪影,以上操作全是在 5 位专业标注人员的监督下进行,保证了数据集的客观性。

Sarkar[53]:该数据集收集大规模室内外场景,包含不同天气和光照条件下的图像,借助 BLIP[54]和 CLIP 为真实图像生成描述,使用 SDXL[55]、Kandinsky-v3[56]、DeepFloyd IF 和 PixArt-α[57]生成模型来生成图像,确保真实图像与生成图像在语义内容上的可比性。使用 ResNet-50 作为预筛选器,筛除能轻易分类的生成图像,保证了数据集质量。

WildFake[58]:该数据集注重内容的丰富性,集成了 COCO[59]、FFHQ[35]、ImageNet[28]、LSUN[60]和 LAION-5B[61]等真实图像数据集。为保证生成图像的多样性,采用了扩散模型、生成对抗网络和变分自编码器等多种生成架构。在扩散模型方面,汇集了 SD[12]、DDPM[6]、DDIM[8]、DALL-E、Imagen[14]、MJ 等 8 个模型及其不同版本。此外,还从生成模型社区中抓取了大量广泛传播的生成图像,以进一步丰富图像的多样性。

Holmes-Set[62]:该数据集包含两个部分:一是 6.5 万张图像的微调集,由 4 个视觉大语言模型交叉标注,输出详细的真伪原因解释;二是 2 000 张图像的人类偏好集,经人工修正文本,服务于可解释性检测的基础需求。

Chameleon[48]:该数据集收集主流 AI 绘画社区用户创建的图像和摄影师拍摄的高质量真实图像,为了保证生成图像质量,筛除低像素图像,过滤不安全内容,去除重复样本,以确保语义统一,最后由专业人类标注人员挑选出高质量图像。

Community Forensics[63]:该数据集聚焦于生成图像多样性检测问题,为了解决检测算法对未知模型检测泛化性不足的问题,从共享社区 Hugging Face 上下载开源文生图扩散模型,每个模型生成 403 张图像。在探讨多生成模型架构方面,系统性地收集了 19 个开源生成模型架构,并收集了 11 个最先进的商业模型来生成图像。同样,为保证真实图像在风格和内容上的多样性,选取了 LAION、ImageNet、COCO、FFHQ、CelebA[64]等多个真实图像数据集。

依据现有数据集,根据其设计目的与评估情况,可将其分为 5 类:以 GenImage[23]、UniversalFakeDetect[33]、WildFake[58]和 Community Forensics[63]为代表的数据集涵盖多种生成架构,主要用于评估模型在不同模型架构上的泛化能力;DiffusionFace[44]和 DiffusionForensics[31,65]侧重于评估模型在对抗扰动下的鲁棒性;SynthScars[46]、SID-Set[52]和 Holmes-Set[62]提供了像素级掩码与文本表述,填补了可解释性与定位能力评估的空白;Fake2M[45]和 Chameleon[48]聚焦于高质量难样本,研究检测模型的性能极限;Sarkar[53]构建的数据集则专注于光照与集合物理规律的一致性评估。具体的数据集参数总结如表 2 所示。

3.2 检测技术性能评估

基于扩散模型的生成图像检测技术作为伪造图像检测的分支,其性能评估可以参照伪造图像检测方向的内容[66-67]。在伪造图像检测中,通常将数据集分为真实图像和伪造图像,经过检测技术获得的检测结果被分为 4 种情况:TP(N_{TP}),被正确预测的正例,即该数据的真实值为正例,预测值也为正例的情况;TN(N_{TN}),被正确预测的反例,即该数据的真实值为反例,预测值也为反例的情况;FP(N_{FP}),被错误预测的正例,即该数据的真实值为反例,但被错误预测成了正例的情况;FN(N_{FN}),被错误预测的反例,即该数据的真实值为正例,但被错误预测成了反例的情况。

通常使用准确率(A)、精确率(P)、召回率(R)、F1 值(F_1)指标来评估检测技术的性能。

$$A=\frac{N_{TP}+N_{TN}}{N_{TP}+N_{FP}+N_{TN}+N_{FN}} \tag{5}$$

$$P=\frac{N_{TP}}{N_{TP}+N_{FP}} \tag{6}$$

$$R=\frac{N_{TP}}{N_{TP}+N_{FN}} \tag{7}$$

计算机工程 www.ecice06.com

表 2 数据集统计

Table 2 Dataset statistics

Dataset	Models	Sizes	Classes	Labels	Assessment Abilities
GenImage[23]	GAN/DM	268.0W	8	None	Generalization
DiffusionForensics[31,65]	DM	46.4W	8	None	Robustness
UniversalFakeDetect[33]	GAN/DM	—	15	None	Generalization
DiffusionFace[44]	DM	63.0W	11	Machine Annotation	Physical
Fake2M[45]	GAN/DM/AR	230.0W	11	None	High-Quality
SynthScars[46]	GAN/DM	1.2W	—	Manually Annotated	Interpretability
Chameleon[48]	GAN/DM	2.6W	9	Manually Annotated	High-Quality
SID-Set[52]	GAN/DM	30.0W	2	Machine Annotation	Interpretability
Sarkar[53]	GAN/DM	52.5W	4	None	Physical
WildFake[58]	GAN/DM/VAE	350.0W	29	None	Generalization
Holmes-Set[62]	GAN/DM	6.9W	18	Machine and Manually Annotation	Interpretability
Community Forensics[63]	GAN/DM	270.0W	4 803	None	Generalization

$$F_1=2\times\frac{P\times R}{P+R} \tag{8}$$

准确率表示分类正确的样本占总样本个数的比例。精确率又叫查准率，表示预测结果为正例的样本中实际为正样本的比例。召回率又称为查全率，表示预测结果为正样本中实际正样本数量占全部样本中正样本的比例。F1 值是精确率和召回率的加权调和平均。

通过这些指标可以很好地评估一个检测技术针对某一种生成模型的检测性能。为了进一步评估在不同生成模型和多种场景下检测技术的性能，还需要考虑泛化性和鲁棒性两个重要参考指标。泛化性是指检测技术在未见数据集或未知生成模型上的表现能力。在本文探讨的范围内，主要指生成图像检测模型能否有效地识别由不同扩散模型（如 SD、MJ、DALL-E3 等）生成的图像，尤其是模型训练时未见过的生成器，也指检测模型在不同领域（如人脸、风景、抽象艺术等）、分辨率、风格的图像上的表现。鲁棒性反映了检测模型抵御对抗性攻击或后处理操作的能力，通常指检测技术在面对常见的图像编辑操作（如压缩、裁剪、缩放、添加噪声、颜色和对比度调整等）时性能会出现不同程度的下降，或者指检测技术抵御对抗性样本攻击的能力。

4 扩散模型生成图像检测技术

大规模的扩散模型生成图像应用引发了较大的争议，使人们对社交媒体中图像内容的真实性产生忧虑，这也促进了生成图像检测技术的发展。借助所建立的数据集，从而寻找真实图像和生成图像之间的差异是所有真伪图像检测的要点，扩散模型的文生图拥有多步去噪的过程，使得这类图像具有一定的生成过程差异。基于这些原因，将基于扩散模型生成图像的检测技术分为基于隐式特征的检测技术、基于显式特征的检测技术和基于混合特征的检测技术。

4.1 基于隐式特征的检测技术

4.1.1 端到端的隐式特征检测技术

在真伪图像鉴别任务中，最常见的方法是二分类方法，即使用监督学习的方法，依托大规模标注数据集，将数据集图像分为真和伪两类作为输入，使用深度学习方法直接进行真伪图像分类，并输出真或伪的类别结果。最常用的模型可以分为以卷积神经网络（CNN）为基础的端到端深度学习[68-72]和以视觉 Transformer（ViT）[20,73]为基础的端到端深度学习技术[74]。虽然这些方法在单一类别的检测任务中取得了优异的表现，但是泛化到多类生成图像检测任务中，其检测精度骤然下降。为了解决这个问题，EPSTEIN 等[68]使用 ResNet-50 作为二元分类器，按照时间顺序收集多类生成图像，将同类图像逐步补充训练，在多类生成图像检测任务中达到了较高的性能。除此之外，通过改变训练策略，也能在一定程度上提升算法的泛化性能。DAS 等[75]在数据集处理阶段对图像进行随机翻转、旋转、亮度调整等操作，冻结 ResNet-50 前 4 个卷积层，从第 5 个卷积层重新初始化权重，在真伪图像检测中获得了较优的表现。在模型轻量化方面，ZHU 等[76]使用知识蒸馏技术，避免硬标签带来的过拟合问题，建立老师-学生模型来平衡软标签和硬标签，最终使用学生模型来输出分类结果。在无监督学习方面，RIGID[77]则使用 DINOv2[78]表示图像空间中微小噪声扰动，而 AI 生成图像更敏感，通过计算原始图像与噪声扰动版本之间的余弦相似度进行检测。

计算机工程 www.ecice06.com

4.1.2 大语言模型检测技术

基于扩散模型的文生图是由文本到图像的模态转变,很多学者假设带有文本限制的生成图像会包含特定的文本特征。依据这一假设,在真伪识别中寻找文本特征也是一项重要任务。很多学者在检测基于扩散模型的文生图任务时,将这种语义特征作为重要的识别特征。通过使用 CNN 提取低层特征,结合 CLIP 模型提取的高层语义特征,直接在多类生成图像检测的任务中取得了良好的泛化性能[79-80]。通过实验对比,CLIP 与 ViT 的结合产生的多模态大语言模型 CLIP-ViT[81]可以直接结合语义特征和纹理特征,其性能在生成图像检测任务中远优于 CNN 与 CLIP 的结合模型[33,82-85]。在此基础上,以 CLIP-ViT 模型作为特征提取器,结合 SVM[86]、回归模型[87]等分类器来检测生成图像。虽然 CLIP-ViT 模型在跨模态特征结合方面的能力优异,但是随着扩散模型生成图像的发展,其在新版本的图像检测任务中表现不佳,学者进一步挖掘大语言模型的文本特征,并试图结合多类特征来提升其在高质量生成图像检测任务中的泛化性能。

随着深度学习算法的发展,一些学者发现通过预训练大语言模型能够直接提取更多尺度的图像特征,这些图像特征在生成图像检测任务中具有更优异的分类能力。在此基础上,DF-LLaVA[88]和 AntifakePrompt[89]通过提示引导的知识激活方法,设计“请分析此图像是否可能存在 AI 生成的伪影,并指出可疑区域”等结构化提示,将二分类问题转化为开放式的视觉问答。通过训练轻量级的适配器或进行提示调优,将关于生成图像典型伪影(如纹理矛盾、物理失真)的领域知识注入模型,使其回答更专注于检测任务。近期,AIGI-Holmes[62]、FakeVLM[85]、SIREN[90]等工作设计专门的大语言模型,输入图像后直接输出“真假”判断,并附带一段自然语言解释,指出具体的可疑伪影,如“阴影方向不一致”“头发纹理过于平滑”。

4.1.3 小结

基于隐式特征的检测技术,通过挖掘高维抽象特征实现分类判定,在训练数据中能获得极高的检测精度,但是在跨模型泛化问题中检测精度出现明显下滑,且难以有效应对快速迭代的生成模型所带来的挑战。这类方法虽然在特定生成模型的检测上表现出极高的准确率,但其局限性在于极易陷入过拟合陷阱,模型往往倾向于学习训练数据中特定、非本质的虚假特征(如特定背景噪声或模型缺陷所带来的边缘伪影),而非生成图像的通用指纹,致使其泛化能力较差。

随着技术的发展,利用预训练大语言模型强大的通用知识库、语义理解能力以及更智能的逻辑推理能力,检测模型不仅能捕捉视觉上的像素差异,还能从语义一致性、常识逻辑等更高维度进行综合分析。这种转变使得隐式特征检测结果更加全面和智能,有效缓解了传统深度分类器泛化性不足的问题,为检测结果提供了更好的可解释性。预训练大语言模型的检测技术虽然取得了优异成效,但此方案因涉及大规模模型参数的优化和推理,其计算成本与资源消耗显著增高,制约了其在实际应用场景中的部署和普及。

4.2 基于显式特征的检测技术

生成图像与真实图像经历了不同的生成过程,这些过程会在图像中产生不同的伪影,寻找并识别这些伪影,并以这些伪影来制作专用生成图像检测器,是真伪图像检测任务中的常见方法。本节为了区别于隐式的抽象特征,将这种方法称为基于显式特征的检测技术。

4.2.1 空域特征

基于空域统计特征的检测方法的核心假设为:生成模型由于其网络结构、训练目标或优化过程的局限性,无法完全复现自然图像在像素级统计上的复杂分布,从而会在颜色、局部纹理及噪声模式中留下可量化的痕迹。基于这一假设,一些方法探讨了图像局部特征检测的有效性。其中 SSP 方法[91]通过提取单个图像块的噪声模式并将其输入二分类器,展示了极佳的鲁棒性。为了更系统地捕捉这些统计差异,MLEP 方法[92]在多个尺度上从打乱的图像分块中计算香农图像熵,从而提取跨尺度和维度的像素依赖性特征,同时降低对图像语义内容的偏置。WONG 等[93]通过计算图像块内对角线、反对角线方向的像素方差等局部统计量,捕捉生成图像中不自然的平滑性或噪声缺失。此外,GLDF 方法[94]关注复杂纹理区域中像素间异常的空间依赖性,通过频率感知关联发现模块来识别这些细微的伪影空间缺陷。这些方法本质上都利用了生成网络中上采样操作符等对图像像素局部相互依赖性造成的系统性影响。

与专注于低级统计伪影的方法不同,一些空域检测方法侧重于更高层次的结构一致性或特征融合。在结构特征方面,DAS 等[95]发现 AI 生成图像通常表现出更平滑的纹理、更弱的边缘和更少的噪声,因此提出了结合 ViT 和边缘增强模块的混合框架,通过计算边缘差异图的方差来增强对细粒度结

构线索的敏感性。更进一步地，几何不一致性方法[53]完全脱离了像素级信号，转而利用生成模型处理投影几何时的系统性错误，如阴影对齐和消失点精度的错误。这种方法仅检查几何属性，证明了高层空间结构特征的有效性。而 GLFF 框架[96]则采取了折中策略，通过一个局部特征分支来提取精细的局部伪影，并将其与多尺度的全局语义特征融合，以期学习到更具判别性的表示，从而提高在真实世界后处理场景下的鲁棒性。

在颜色统计方面，UHLENBROCK 等[97]指出，生成模型广泛使用的感知损失函数对亮度差异更为敏感，导致其对色度信息的重建存在偏差。该研究通过分析 RGB 通道间的相互关系，发现生成图像与真实图像存在系统性差异，并利用简单的手工颜色特征结合随机森林分类器实现了高效的检测。

4.2.2 频域特征

无论是生成对抗网络还是扩散模型，在图像生成过程中都会在频率域留下独特、与自然图像统计分布不符的频率伪影或指纹。在特征提取和转换的策略上，DOGOULIS 等[98]使用轻量级的 ResNet，对离散小波变换提取的高频特征进行训练，实现了生成图像检测的泛化性能突破。类似地，CHENG 等[99]使用 Sobel 算子提取边缘图，将其作为正则项融入原图输入分类器训练。ZHONG 等[100]发现生成模型的高频纹理细节比全局语义特征具有更明显的差异，且真实图像的纹理区域像素关联性更强。为了简化补丁策略，CHEN 等[91]选取纹理复杂度最低的补丁来提取高频特征，提高了性能。

为了提取到更多的高频特征，LU 等[101]先将图像灰度化变换，使用中值滤波获取低频分量，通过原图与低频分量作差来增强高频信息，再使用快速傅里叶变换（FFT）提取频域特征进行训练。DOLORIEL 等[102]使用 FFT 将图像转换到低频、中频、高频和全频段，然后使用随机掩码来评估伪造特征[103]，使算法的泛化能力得到显著提升。BARU 等[104]采用了小波变换来对图像进行多尺度分解，实现对空间和频率特征的深度整合分析，这尤其适用于对人脸深度伪造的精细检测。相比之下，LANZINO 等[105]直接利用 FFT 将图像转换到频率域以提取谱特征，并通过结合二值神经网络提高实时检测的效率。KARAGEORGIOU 等[106]更侧重于建模真实图像固有的谱分布不变性，并利用傅里叶频谱作为核心线索[107]，将伪造图像识别为与真实分布存在显著差异的分布外样本。ZHANG 等[108]分析了不同模型中的高频特征作为模型泛化的特征，提出 DEFEND 表示，动态抑制低频、增强高频，提升算法的泛化性与鲁棒性。

为最大化频域伪影的鉴别力并提升对未知生成器的泛化能力，研究者提出了多类利用策略。一类是频率特征选择：文献[107-108]均基于扩散生成图像与真实图像的差异在低频到高频波段上递增的观察，设计了频率选择函数或加权滤波器，以在傅里叶频谱上增强关键的伪造线索，同时抑制低区分度信息。另一类是频域特征的增强：文献[109]使用像素信号映射的方式将低频特征转为高频特征，实现了频域特征的显著增强。

4.2.3 嵌入式特征

主动检测一直是真伪图像检测中的重要分支，但是这类方法的研究还不够充分。WEN 等[110]提出的树环水印方法通过将图案嵌入初始噪声矢量来实现水印。这些图案在傅里叶空间中构建，对卷积、裁剪、膨胀、翻转和旋转均表现出强鲁棒性。生成图像后，只需反转扩散过程即可检索噪声向量并检测水印信号。

4.2.4 小结

基于显式特征的检测技术旨在发掘图像生成过程中在空域、频域留下的可量化、可识别的系统性伪影或缺陷。在空域特征层面，研究者主要关注于生成图像在像素级统计（如局部纹理、噪声模式、图像熵）和高层结构一致性（如边缘、颜色统计、几何不一致性）上的偏差，通过捕捉这些与自然图像分布相悖的痕迹进行鉴别。在频域特征层面，则侧重于利用傅里叶变换或小波变换等手段，揭示生成模型在频率域中留下的独特伪影或指纹，并通过增强高频差异、建模频谱不变性来提升对未知生成器的泛化能力。此外，嵌入式特征（主动水印）也为该方向提供了新的思路。

与隐式特征检测方法不同的是，该类技术具有较强的可解释性，且对于具有相同或者相似指纹的生成模型图像具有较强的泛化性。然而，该类方法的性能受限于生成模型的更新迭代。随着生成模型的优化，早期的棋盘格效应、高频阶段伪影[111]逐渐减弱甚至消失，导致依赖特定显式指纹的检测方法泛化性降低。此外，显式特征在后处理操作中效果不佳，图像的压缩、裁剪或滤波等操作可能会破坏微弱的指纹信息，导致检测算法的鲁棒性表现出较大的差异。因此，如何挖掘在模型迭代中依然保持稳定的显式不变量是该领域未来的关键挑战。

4.3 基于混合特征的检测技术

混合特征指纹检测方法致力于将显式特征和隐

计算机工程 www.ecice06.com

式特征相融合,以提高检测在复杂场景下的鲁棒性和泛化性。基于扩散模型的生成图像在生成过程中通过 U-Net 框架来生成图像,卷积和上采样处理是这个过程的核心,所以假设基于这类技术生成的图像具有一定的特性和模型指纹。基于这个假设,形成了重建残差检测技术和模型指纹检测技术。

4.3.1 多层级混合特征检测技术

结合早期针对 GAN 等模型的检测技术,CORVI 等[112]通过分析功率谱密度和自相关函数,发现基于扩散模型生成的图像在频域存在独特的谱峰,并在空间域存在异常的规则模式。这些痕迹被证实与生成网络中,特别是 CNN 中的上采样操作息息相关,反映了局部像素间异常的依赖关系。LIU 等[113]先使用卷积提取图像的低维特征,结合 DCT 和注意力机制提取频域特征,再通过 CLIP 预训练的文本-图像对齐能力来强化伪造特征。

WIßMANN 等[114]在 Whodunit 方法中,将功率谱密度、离散余弦变换和自相关函数等传统显式特征作为神经网络分类器的输入,可在完成检测任务的同时,有效识别出生成该图像的具体合成模型。这种方法通过神经网络学习到的高维内部表示,巧妙地融合了显式特征与隐式特征的优势。为了缓解现有方法在面对未见生成器时的性能下降问题,MENG 等[115]提出伪影特征净化网络(APN),通过显式和隐式净化机制来增强伪影的提取,以克服未见分布差异,提升了检测器对不同生成模型和复杂场景的泛化能力和鲁棒性。这些融合多源信息的方法在跨领域检测和模型归属等要求更严格的应用场景中表现出更强的适应性和优越性。

4.3.2 重建误差的混合特征检测技术

重建误差检测技术是利用扩散模型对自身生成内容具有更强重构能力的特性来进行真伪鉴别。WANG 等[31]提出了 DIRE 方法,通过计算原图与经过 DDIM 反演及重构后的图像在像素空间中的绝对差值来区分真伪,其核心假设是生成图像属于生成分布,因此重构误差较小。然而,该方法计算过程繁琐且对 JPEG 压缩等后处理较为敏感。为了解决计算成本问题,RICKER 等[116]提出了 AEROBLADE,利用潜在扩散模型中预训练自动编码器的重构距离作为检测依据,无需训练即可实现快速检测。此外,MA 等[117]提出的 SeDID 则利用确定性的反向和去噪过程,计算生成过程中的逐步误差以捕捉细微差异。

为了克服常规检测技术在效率和抗干扰性上的局限,受隐空间扩散技术启发(如图 3 所示),研究者开始转向利用模型内部的高维抽象表征进行检测。LUO 等[118]针对 DIRE 方法[31,65]速度慢的问题,提出了基于潜在重构误差的方法 LaRE^2,通过将图像编码为潜在特征并在潜在空间中进行单步去噪预测误差,不仅将检测速度提升了 8 倍,还通过误差引导特征细化模块保留了关键的判别线索。

针对频域特征的挖掘,CHU 等[119]观察到扩散模型难以准确重构真实图像的高频信息,因此提出了 FIRE 方法,通过频率掩膜优化模块对比滤波前后的重构误差变化,从而提升了检测的鲁棒性。KARAGEORGIOU 等[106]则认为真实图像的频谱分布是一种不变模式,提出了 SPAI 方法,通过自监督学习训练 ViT 网络重构真实图像频谱,并在高维 Token 嵌入空间计算频谱重构相似度,从而将生成图像视为分布外样本进行检测,显著提升了对不同分辨率和未知生成器的泛化能力。

4.3.3 模型指纹的混合特征检测技术

模型特征检测技术旨在提取更具模型特异性的高维抽象特征,这类方法往往通过深度学习或挖掘生成模型的内部机制来获取。LIANG 等[120]则从生成过程入手,探索了图像去噪轨迹偏差,利用去噪轨迹沿线的相似性作为判别指标,展现出强大的零样本泛化潜力。另外,SINITSA 等[121]和 TAN 等[122]提出 Deep Image Fingerprint 和 LGrad 框架,分别利用 CNN 架构属性和学习预训练 CNN 的梯度来构建广义伪影表示,以实现跨模型、跨数据的泛化检测。

面对 DALL-E3 等高保真生成模型,单一信号往往难以奏效,因此很多工作致力于融合显式视觉信息与隐式生成指纹。CAZENAVETTE 等[123]提出了 FakeInversion,构建了包含原始图像、反演噪声图和重构图像的三元组输入,通过结合显式的视觉外观与隐式的噪声指纹,在检测未见过的光写实模型时达到了新的 SOTA 水平。ZHANG 等[124]提出的 DNF,利用扩散模型的逆过程放大高频伪影,从预训练模型的逆过程中提取估计噪声序列并进行特征融合,有效捕捉了生成图像特有的噪声指纹。此外,CHEN 等[125]提出的 DRCT 框架利用重构过程生成“困难样本”,通过对比学习强迫分类器区分真实图像及其重构版本,从而提高了模型对细微生成痕迹的敏感度与泛化性。

4.3.4 小结

面对隐式特征泛化性受限和显式特征鲁棒性不足的双重挑战,基于混合特征的检测技术应运而生。该类方法旨在结合两者的优势,通过同时利用深层的语义隐式特征和物理层面的显式伪影,构建更加

全面、稳健的检测体系。混合特征识别能够有效弥补单一特征检测的不足，从而显著提升检测的准确率和泛化能力。然而，这种性能的提升也伴随着代价：一方面，混合架构要求模型具备更复杂的特征对齐能力，需要解决不同域（如频域与语义域）特征的融合与互补问题；另一方面，多分支的特征提取与融合处理显著增加了模型的计算成本和推理时延。因此，如何在保证检测性能的同时优化计算效率，实现特征的高效对齐与融合，是混合特征检测技术进一步实用化需要解决的核心问题。

本文绘制了基于扩散模型的生成图像检测技术演进图（如图 5 所示）和性能对比表（如表 3 所示），从而更系统地阐述扩散模型生成图像检测技术的发展历程与性能表现。

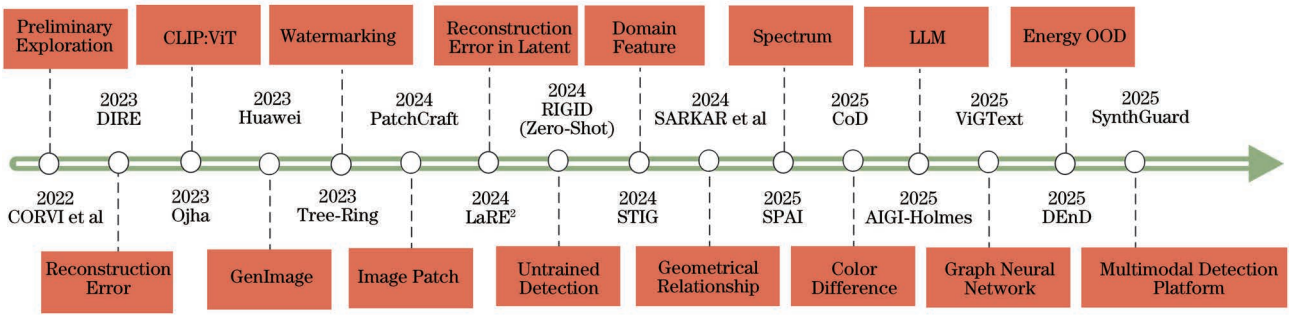


图 5 基于扩散模型的生成图像检测技术演进图

Fig. 5 Evolution diagram of image detection technology based on DMs

表 3 基于扩散模型的生成图像检测技术性能对比

Table 3 Performance comparison of generative image detection techniques based on DMs

Years	Literatures/Techniques	Methods	Dataset	ACC/AP/AUC/%	Generalization	Robustness
2022	Reference [126]	Multi-Detector Evaluation	DALL-E2	50.40/—/—	Low	Low
			GLIDE	62.50/—/—		
			LatentDiffusion	97.10/—/—		
			SD	99.70/—/—		
			ADM	52.90/—/—		
2023	DIRE[31]	Reconstruction Error	ADM	98.80/100.00/—	High	High
			LDM	100.00/100.00/—		
			VQDM	100.00/100.00/—		
			SDv1	95.20/100.00/—		
			SDv2	100.00/100.00/—		
2023	Reference [33]	CLIP:ViT	Ojha •	81.38/93.38/—	Medium	—
2023	Reference [86]	CLIP:ViT+SVM	DALL-E2	—/—/86.30	Medium	Medium
			DALL-E3	—/—/92.90		
			GLIDE	—/—/99.70		
			LatentDiffusion	—/—/84.70		
			SD	—/—/91.30		
			ADM	—/—/79.90		
2024	AEROBLADE[116]	Reconstruction Error	MJv4	—/99.90/—	High	—
			MJv5	—/99.70/—		
			SDv1	—/97.80/—		
			SDv2	—/99.40/—		
2024	LaRE²[118]	Reconstruction Error	GenImage •	85.90/99.80/—	Medium	—
2024	DRCT[125]	Reconstruction Error with VAE	GenImage •	89.49/—/—	High	—
			SDXL	95.61/—/—		
			SDv2	95.05/—/—		

表 3(续)

Years	Literatures/Techniques	Methods	Dataset	ACC/AP/AUC/%	Generalization	Robustness
2025	Reference [24]	Reconstruction Error with LDM	SD	99.57/—/—	High	High
			MJ	99.37/—/—		
			Kandinsky	99.57/—/—		
			PixelArt-α	100.00/—/—		
2025	Reference [25]	Reconstruction Error with SD2.1	MJ	99.60/—/100.00	High	Medium
			SDXL	99.80/—/100.00		
			DALL-E2	95.60/—/99.70		
			DALL-E3	98.20/—/99.90		
			FLUX	92.30/—/99.30		
2025	MLEP[92]	Image Patch	ADM	97.00/99.80/—	High	—
			LDM	99.80/100.00/—		
			VQDM	100.00/100.00/—		
			SDv1	98.50/99.90/—		
			SDv2	100.00/100.00/		
2025	GLDF[94]	Spatial and Frequency Domain Features	GenImage •	97.54/99.76/—	High	—
			DiffusionForensics •	92.74/98.72/—		
			FLUX	94.46/99.27/—		
			SDv3	89.32/98.85/—		
2025	SPAI[106]	Spectrum	SDv1	—/—/99.60	High	—
			FLUX	—/—/83.00		
			SDXL	—/—/97.40		
			DALL-E3	—/—/90.20		
			MJv6.1	—/—/84.00		
2025	Reference [108]	Frequency Domain Features	GenImage •	99.99/100.00/—	High	—
			DiffusionForensics •	100.00/100.00/—		
2025	FIRE[119]	Frequency Domain Features and Reconstruction Errors	ADM	100.00/—/100.00	High	—
			LDM	100.00/—/99.80		
			VQDM	100.00/—/100.00		
			SDv1	100.00/—/100.00		
			SDv2	100.00/—/100.00		
2025	DNF[124]	Model Fingerprint	ADM	100.00/100.00/—	High	Low
			LDM	100.00/100.00/—		
			VQDM	99.80/100.00/—		
			DALL-E2	100.00/100.00/—		
			SDv2	100.00/100.00/—		
2025	Reference [127]	CLIP+VIB	GenImage •	89.21/98.06/—	High	—
2025	Reference [128]	Color	Ojha •	97.50/99.40/—	High	—
			GenImage •	96.20/99.40/—		

由图 5 可以看出，基于扩散模型生成图像检测技术自 2022 年开始受到学者关注，在 2023 年开始相关学者基于生成模型对真实图像和生成图像进行重建，增大了两类图像之间的差异，提出了重构误差的方法。随着多模态大语言模型的发展，其海量的知识储备在生成图像检测领域具有天然的优势，使得很多工作围绕类似于 CLIP、ViT 这类大语言模型展开。主动检测技术一直是伪造图像检测的重点，在生成图像领域虽有涉及但是工作极少。2024 年，参照深度伪造图像的检测方法，相关学者从空间域

计算机工程 www.ecice06.com

提出了几何投影一致性检测、图像分块等检测技术，从频率域提出了多类频域特征分析的检测技术。随着对以上检测技术的深化探索，结合大语言模型的发展，基于扩散模型生成图像检测技术逐步向少样本训练乃至无样本训练，达到直接特征提取检测或者使用大语言模型直接产生解释文本的路径发展。

在表 3 中，“ • ”代表开源的公开数据集，“—”代表文中未作相关实验或者未给出相应指标值。此外，表 3 中各检测性能评估依据本文第 3.2 节所述。泛化性主要考察检测技术对未见生成模型及跨架构生成图像的检测能力，其中，“高”表示模型在跨架构或多种未见生成模型上精度达到 90%以上；“中”表示模型在同类生成架构间泛化性较好，但在跨架构测试中有一定的衰减，精度在 80%～90%之间；“低”表示模型仅在训练集中表现良好，但泛化性能表现不佳，在多类生成模型中检测精度在 80%以下。鲁棒性主要考察模型对抗常见后处理与扰动能力，其中，“高”表示模型在经历 JPEG 压缩、高斯模糊等干扰后，检测精度达到 90%以上；“中”表示模型只能面对轻微扰动，对高强度扰动效果不佳，精度在 80%～90%之间；“低”表示模型对后处理操作敏感，经过扰动后检测性能近乎失效，在多类检测数据集中检测精度在 80%以下。

5 总结与展望

5.1 总结

基于扩散模型的生成图像技术从早期的无条件图像生成，到引入文本、类别等条件控制的可控生成，再到精细化的图像编辑与修复，扩散模型的应用边界不断拓展。近年来，该技术已延伸至视频生成、三维内容合成等多模态领域，并与大语言模型深度融合，形成了强大的视觉语言联合生成系统。这些进展使得用户能够通过自然语言描述直接生成高质量的视觉内容，极大地降低了内容创作的门槛，但同时也对图像真实性鉴别提出了前所未有的挑战。

在数据集建设方面，当前数据集在语义一致性、内容逼真度、数据规模、样本分布以及标注格式等方面均实现了显著提升，力求在多个层面贴近真实图像的统计特性与语义结构，为检测算法的训练与评估提供了丰富的数据资源。数据集建设呈现出 3 个明显的演进阶段：早期数据集主要针对生成模型架构单一、图像质量较低、分辨率受限等问题，虽然能够支持基本的真伪分类任务，但数据偏差、语义不对齐等问题未能得到有效解决；随着生成技术的进步，中期数据集开始涵盖更多生成场景和模型架构，图像分辨率和真实感显著提升；最新一代数据集则引入了详细的像素级标注、文本化的可解释标签，并采用多级筛选策略，结合自动化工具与人工审核来保证数据质量，使得检测算法能够更细致地学习真实图像与生成图像之间的差异特征，提升了检测结果的可靠性与权威性。然而，由于不同数据集针对的检测重点存在差异（如特定生成器、特定应用场景或特定伪影类型），目前尚未形成一个能够同时满足多方面需求的统一标准数据集。

在检测算法性能方面，近年来提出的多种方法在特定数据集上取得了优异的表现，部分基于扩散模型生成图像的检测准确率已达到 99%以上，展现出深度学习方法在该任务上的强大能力。然而，当前技术仍面临若干关键挑战，制约了其在实际场景中的广泛应用。具体而言，当前研究存在以下 3 个方面的主要不足：

1）数据集标准化程度不足。测试数据集的不统一是当前研究的突出问题。部分研究采用早期公开数据集（如 GenImage、DiffusionForensics 及 Ojha 数据集）进行测试，但这些数据集所使用的生成器版本较旧、模型类型单一、图像质量控制不严格，难以反映最新生成技术的真实水平。更多研究则倾向于构建自建数据集进行评估，导致不同研究成果之间缺乏横向可比性，难以客观评价各方法的相对优劣。这一现状表明，建立具有广泛认可度和代表性的标准测试基准已成为领域发展的迫切需求。

2）评估指标体系有待完善。当前文献中使用的评估指标较为多样，主要包括准确率、平均精度（AP）、F1 值、ROC 曲线下面积（AUC）等。虽然多数研究同时报告准确率和 AP 两项指标以便于直观比较，但在面对类别不平衡、不同应用场景的性能权衡以及跨数据集泛化能力等问题时，单一或有限的指标体系难以全面反映算法的综合性能。此外，对于可解释性、鲁棒性、计算效率等非传统性能维度的量化评估尚显不足。

3）实际应用场景适应性有限。现有研究大多聚焦于原始生成图像与高质量真实图像的直接对比，而在实际网络传播、社交媒体分享等场景中，图像往往会经历 JPEG 压缩、缩放、滤镜处理等多种后处理操作。这些操作会不同程度地破坏或掩盖生成图像的固有伪影特征，导致检测算法性能显著下降。已有的少数研究在引入图像压缩、噪声扰动等鲁棒性测试后，算法准确率普遍出现较大幅度降低，凸显了当前方法在真实部署环境下的脆弱性。因此，如何提升检测算法对常见图像处理操作的鲁棒性，是实

www.ecice.com 计算机工程

现技术落地的关键问题。

5.2 展望

尽管基于扩散模型的生成图像检测技术在算法创新和性能提升方面取得了显著进展，但在标准化评测体系构建、跨模型泛化能力提升、实际场景鲁棒性增强以及可解释性与实时性的协同优化等方面仍存在较大的改进空间。

5.2.1 标准化评测体系的构建与完善

统一标准测试基准的建立：迫切需要建立一个具有代表性、时效性和广泛认可度的通用标准测试基准集。该基准应涵盖最新、主流的扩散模型架构（如 SDXL、MJv6.1、DALL-E3 等）和多场景应用（如通用生成、图像编辑、视频帧），并提供多级质量控制和细粒度伪影标注，确保不同研究成果之间能够进行公平、可比的横向性能评估。

多维度性能指标的量化评估：现有的评估指标体系（准确率、AP、AUC 等）难以全面反映算法的综合能力。未来应将评估重点拓展至非传统性能维度，包括鲁棒性、泛化性、效率、可解释性。

5.2.2 跨模型泛化与实际应用鲁棒性的提升

通用性鉴别模型的研究：探索超越特定模型指纹、挖掘生成过程共性不变特征的方法，以提升检测器在面对未知生成器时的零样本或少样本泛化能力。

对抗后处理操作的能力：针对图像在传播中经历的多种破坏性操作，需要研发更具对抗韧性的检测算法。这包括在特征提取阶段利用残差分析、频率域滤波等技术增强对被稀释伪影信号的恢复能力；或在训练阶段引入鲁棒性优化策略，迫使模型关注那些不易被后处理破坏的底层结构性特征。

5.2.3 可解释性、模型归属与主动防御体系的构建

精细化伪影定位与可解释归因：发展先进的视觉归因技术，使检测模型能够输出像素级的伪影定位热图，并提供基于自然语言、可解释的判别依据，如“阴影方向不一致”“纹理过平滑”。这对于数字取证和司法审查至关重要。

生成器模型指纹的精确溯源：探索如何从复杂的生成痕迹中提取出稳定、特异的指纹，实现对图像生成模型的精确归属。未来的目标不仅是判断“真假”，更要能够识别出图像是由哪一个具体模型版本或家族所生成。

主动防御与数字水印技术：鉴于检测技术的被动性，应积极研发针对扩散模型生成过程的鲁棒嵌入式数字水印技术。该技术应能够在不影响感知质量的前提下，将版权或真实性标识嵌入到隐式空间（如噪声初始化阶段），并能够抵抗对抗性攻击与后处理破坏。

6 结束语

本文对基于扩散模型的生成图像检测技术进行了全面系统的综述。数据集建设呈现出三个明显趋势：一是生成模型覆盖范围从单一架构扩展到多模型融合；二是图像质量从低分辨率提升至高分辨率、高真实度；三是标注方式从简单二分类标签发展到像素级掩码标注、文本化可解释标注，并引入大语言模型辅助筛选和人工多级审核。这些进步为算法研究提供了更加丰富、规范和贴近实际应用的数据资源。通过对现有文献的深入分析，本文系统梳理了扩散模型生成图像检测技术的三大主流方法体系。基于隐式特征的检测技术依托深度学习架构，通过大规模标注数据实现端到端的真伪分类。基于显式特征的方法从空域统计特性、频域伪影特征和主动嵌入水印等角度切入，具有较强的可解释性和鲁棒性。基于混合特征的检测技术则巧妙利用扩散模型的重建机制和模型指纹特性，集合多类特征，实现了无需训练或轻量训练的检测方案。这些方法各有优势，共同构成了生成图像检测的技术谱系。

基于扩散模型的生成图像技术正在重塑数字内容创作的范式，但技术进步必须伴随相应的治理能力提升。生成图像检测技术不仅是技术对抗的产物，更是维护信息真实性、保护知识产权、维持社会信任的重要工具。随着扩散模型技术持续演进和应用场景不断拓展，检测技术也需要与时俱进，在算法性能、泛化能力、实用性和可解释性等多个维度实现协同提升。本综述期望能够为相关领域的研究者提供全面的技术图谱，为从业者提供系统性的方法参考，共同推动生成图像检测技术向更加成熟、实用的方向发展，助力人工智能技术的健康、可持续发展。

参考文献

[1] XU Q, CHEN D, CHEN J, et al. Recent advances on generalizable diffusion-generated image detection[EB/OL]. [2025-10-16]. http://arxiv.org/abs/2502.19716.

[2] MAHARA A, RISHE N. Methods and trends in detecting AI-generated images: a comprehensive review[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2502.15176.

[3] 刘晓龙，刘欢，赵耀，等. AIGC 伪造内容被动检测与主动防御技术综述[J]. 中国科学(信息科学)，2025，55(9)：2250-2288.
LIU X L, LIU H, ZHAO Y, et al. Review of AIGC passive detection and proactive protection [J]. Scientia Sinica (Informationis), 2025, 55(9): 2250-2288. (in Chinese)

[4] 程泊宣，李明轩，张正宇. 扩散模型生成式图像检测技术研究综述[J]. 计算机工程与应用，2025，61(20)：1-18.

www.ecr.ac.cn 计算机工程

CHENG B X, LI M X, ZHANG Z Y. Review of generative image detection technology based on diffusion[J]. Computer Engineering and Applications, 2025, 61(20): 1-18. (in Chinese)
[5] SOHL-DICKSTEIN J, WEISS E A, MAHESWARANATHAN N, et al. Deep unsupervised learning using nonequilibrium thermodynamics[EB/OL]. [2025-10-16]. https://arxiv.org/abs/1503.03585.
[6] HO J, JAIN A, ABBEEL P. Denoising diffusion probabilistic models[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2006.11239.
[7] SONG Y, SOHL-DICKSTEIN J, KINGMA D P, et al. Score-based generative modeling through stochastic differential equations[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2011.13456.
[8] SONG J M, MENG C L, ERMON S. Denoising diffusion implicit models[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2010.02502.
[9] NICHOL A, DHARIWAL P. Improved denoising diffusion probabilistic models[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2102.09672.
[10] DHARIWAL P, NICHOL A. Diffusion models beat GANs on image synthesis[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2105.05233.
[11] RONNEBERGER O, FISCHER P, BROX T. U-Net: convolutional networks for biomedical image segmentation[C]// Proceedigns of Medical Image Computing and Computer-Assisted Intervention. Berlin, Germany: Springer, 2015: 234-241.
[12] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-resolution image synthesis with latent diffusion models[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D.C., USA: IEEE Press, 2022: 10674-10685.
[13] NICHOL A, DHARIWAL P, RAMESH A, et al. GLIDE: towards photorealistic image generation and editing with text-guided diffusion models[C]//Proceedings of the 39th International Conference on Machine Learning. [S. l.]: PMLR, 2022: 16784-16804.
[14] CHITWAN S, CHAN W, SAXENA S, et al. Photorealistic text-to-image diffusion models with deep language understanding[J]. Advances in Neural Information Processing Systems, 2022, 35: 36479-36494.
[15] HO J, SALIMANS T. Classifier-free diffusion guidance [EB/OL]. [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2207.12598.
[16] MENG C L, HE Y T, SONG Y, et al. SDEdit: guided image synthesis and editing with stochastic differential equations[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2108.01073.
[17] KAWAR B, ELAD M, ERMON S, et al. Denoising diffusion restoration models [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2201.11793.
[18] SAHARIA C, HO J, CHAN W, et al. Image super-resolution via iterative refinement[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 45(4): 4713-4726.
[19] LUGMAYR A, DANELLJAN M, ROMERO A, et al. RePaint: inpainting using denoising diffusion probabilistic models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D.C., USA: IEEE Press, 2022: 11451-11461.
[20] CHOI J, KIM S, JEONG Y, et al. ILVR: conditioning method for denoising diffusion probabilistic models[C]// Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). Washington D.C., USA: IEEE Press, 2022: 14347-14356.
[21] RAMESH A, DHARIWAL P, NICHOL A, et al. Hierarchical text-conditional image generation with CLIP latents[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2204.06125.
[22] GROMMELT P, WEISS L, PFREUNDT F J, et al. Fake or JPEG? Revealing common biases in generated image detection datasets[C]//Proceedings of the ECCV 2024. Berlin, Germany: Springer, 2025: 80-95.
[23] ZHU M J, CHEN H T, YAN Q Y, et al. GenImage: a million-scale benchmark for detecting AI-generated image[C]// Proceedings of the Advances in Neural Information Processing Systems 36. New Orleans, USA: Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2023: 77771-77782.
[24] RAJAN A S, OJHA U, SCHLOESSER J, et al. Aligned datasets improve detection of latent diffusion-generated images[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2410.11835.
[25] GUILLARO F, ZINGARINI G, USMAN B, et al. A bias-free training paradigm for more general AI-generated image detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D.C., USA: IEEE Press, 2025: 18685-18694.
[26] CHEN R X, XI J W, YAN Z Y, et al. Dual data alignment makes AI-generated image detector easier generalizable[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2505.14359.
[27] WANG L, CHEN W, LI Z, et al. PDA: generalizable detection of AI-generated images via post-hoc distribution alignment[EB/OL]. [2025-10-16]. https://arxiv.org/html/2502.10803v1.
[28] DENG J, DONG W, SOCHER R, et al. ImageNet: a large-scale hierarchical image database[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2009: 248-255.
[29] BROCK A, DONAHUE J, SIMONYAN K. Large scale GAN training for high fidelity natural image synthesis[EB/OL]. [2025-10-16]. https://arxiv.org/abs/1809.11096.
[30] GU S Y, CHEN D, BAO J M, et al. Vector quantized diffusion model for text-to-image synthesis[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D.C., USA: IEEE Press, 2022: 10686-10696.
[31] WANG Z D, BAO J M, ZHOU W G, et al. DIRE for diffusion-generated image detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). Washington D.C., USA: IEEE Press, 2023: 22388-22398.
[32] LIU L P, REN Y, LIN Z J, et al. Pseudo numerical methods for diffusion models on manifolds[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2202.09778.
[33] OJHA U, LI Y H, LEE Y J. Towards universal fake image detectors that generalize across generative models[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D.C., USA: IEEE Press, 2023: 24480-24489.
[34] KARRAS T, AILA T, LAINE S, et al. Progressive growing of GANs for improved quality, stability, and variation[EB/OL]. [2025-10-16]. https://arxiv.org/abs/1710.10196.
[35] KARRAS T, LAINE S, AILA T M. A style-based generator architecture for generative adversarial networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D.C., USA: IEEE Press,

计算机工程 www.ecice06.com

2019: 4396-4405.
[36] ZHU J Y, PARK T, ISOLA P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks [C] // Proceedings of the IEEE International Conference on Computer Vision (ICCV). Washington D.C., USA: IEEE Press, 2017: 2242-2251.
[37] CHOI Y, CHOI M, KIM M, et al. StarGAN: unified generative adversarial networks for multi-domain image-to-image translation [C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2018: 8789-8797.
[38] PARK T, LIU M Y, WANG T C, et al. Semantic image synthesis with spatially-adaptive normalization [C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D.C., USA: IEEE Press, 2020: 2332-2341.
[39] CHEN Q F, KOLTUN V. Photographic image synthesis with cascaded refinement networks [C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). Washington D.C., USA: IEEE Press, 2017: 1520-1529.
[40] LI K, ZHANG T H, MALIK J. Diverse image synthesis from semantic layouts via conditional IMLE [C] // Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). Washington D.C., USA: IEEE Press, 2019: 4219-4228.
[41] DAI T, CAI J R, ZHANG Y B, et al. Second-order attention network for single image super-resolution [C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D.C., USA: IEEE Press, 2020: 11057-11066.
[42] CHEN C, CHEN Q F, XU J, et al. Learning to see in the dark [C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2018: 3291-3300.
[43] ROSSLER A, COZZOLINO D, VERDOLIVA L, et al. FaceForensics++: learning to detect manipulated facial images [C] // Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). Washington D.C., USA: IEEE Press, 2019: 1-11.
[44] CHEN Z X, SUN K, ZHOU Z Y, et al. DiffusionFace: towards a comprehensive dataset for diffusion-based face forgery analysis [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2403.18471.
[45] LU Z Y, HUANG D, BAI L, et al. Seeing is not always believing: benchmarking human and model perception of AI-generated images [C] // Proceedings of the Advances in Neural Information Processing Systems 36. New Orleans, USA: Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2023: 25435-25447.
[46] KANG H, WEN S, WEN Z, et al. LEGION: learning to ground and explain for synthetic image detection [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2503.15264.
[47] LIANG Y, HE J, LI G, et al. Rich human feedback for text-to-image generation [EB/OL]//Proceedings of the 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D.C., USA: IEEE Press, 2024: 19401-19411.
[48] YAN S L, LI O X, CAI J Y, et al. A sanity check for AI-generated image detection [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2406.19435.
[49] HUANG Z C, XIA B, LIN Z C, et al. FFAA: multimodal large language model based explainable open-world face forgery analysis assistant [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2408.10072.
[50] HE K M, ZHANG X Y, REN S Q, et al. Deep residual learning for image recognition [EB/OL]. [2025-10-16]. https://arxiv.org/abs/1512.03385.
[51] WANG P, BAI S, TAN S N, et al. Qwen2-VL: enhancing vision-language model's perception of the world at any resolution [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2409.12191.
[52] HUANG Z L, HU J W, LI X T, et al. SIDA: social media image deepfake detection, localization and explanation with large multimodal model [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D.C., USA: IEEE Press, 2025: 28831-28841.
[53] SARKAR A, MAI H L, MAHAPATRA A, et al. Shadows don't lie and lines can't bend! Generative models don't know projective geometry... for now [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D.C., USA: IEEE Press, 2024: 28140-28149.
[54] LI J N, LI D X, XIONG C M, et al. BLIP: bootstrapping language-image pre-training for unified vision-language understanding and generation [C] // Proceedings of the International Conference on Machine Learning. Washington D.C., USA: IEEE Press, 2022: 12888-12900.
[55] PODELL D, ENGLISH Z, LACEY K, et al. SDXL: improving latent diffusion models for high-resolution image synthesis [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2307.01952.
[56] ARKHIPKIN V, FILATOV A, VASILEV V, et al. Kandinsky 3.0 technical report [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2312.03511.
[57] CHEN J S, YU J C, GE C J, et al. PixArt-α: fast training of diffusion transformer for photorealistic text-to-image synthesis [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2310.00426.
[58] HONG Y, ZHANG J F. WildFake: a large-scale challenging dataset for AI-generated images detection [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2402.11843.
[59] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft COCO: common objects in context [EB/OL]. [2025-10-16]. https://arxiv.org/abs/1405.0312.
[60] YU F, SEFF A, ZHANG Y D, et al. LSUN: construction of a large-scale image dataset using deep learning with humans in the loop [EB/OL]. [2025-10-16]. https://arxiv.org/abs/1506.03365.
[61] SCHUHMANN C, BEAUMONT R, VENCU R, et al. LAION-5B: an open large-scale dataset for training next generation image-text models [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2210.08402.
[62] ZHOU Z Y, LUO Y P, WU Y C, et al. AIGI-Holmes: towards explainable and generalizable AI-generated image detection via multimodal large language models [C] // Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). Washington D.C., USA: IEEE Press, 2025: 18746-18758.
[63] PARK J, OWENS A. Community Forensics: using thousands of generators to train fake image detectors [C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D.C., USA: IEEE Press, 2025: 8245-8257.
[64] LIU Z W, LUO P, WANG X G, et al. Deep learning face attributes in the wild [C] // Proceedings of the IEEE International Conference on Computer Vision (ICCV). Washington D.C., USA: IEEE Press, 2016: 3730-3738.
[65] VASILCOIU A, NAJDENKOSKA I, GERADTS Z, et al.

计算机工程 www.ecice06.com

LATTE: latent trajectory embedding for diffusion-generated image detection[EB/OL]. https://ui.adsabs.harvard.edu/abs/2025arXiv250703054V/abstract.
[66] 马静, 车进, 孙末贤. 融合 Transformer 与 DF-GAN 的文本生成图像方法[J]. 计算机工程, 2026, 52(2): 413-422.
MA J, CHE J, SUN M X. Text-to-image generation method combining Transformer and DF-GAN [J]. Computer Engineering, 2026, 52(2): 413-422. (in Chinese)
[67] 张汝波, 蔺庆龙, 张天一. 基于深度学习的图像篡改检测方法综述[J]. 智能系统学报, 2025, 20(2): 283-304.
ZHANG R B, LIN Q L, ZHANG T Y. A review of image tampering detection methods based on deep learning[J]. CAAI Transactions on Intelligent Systems, 2025, 20(2): 283-304. (in Chinese)
[68] EPSTEIN D C, JAIN I, WANG O, et al. Online detection of AI-generated images[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW). Washington D.C., USA: IEEE Press, 2023: 382-392.
[69] LU Z Y, HUANG D, BAI L, et al. Seeing is not always believing: benchmarking human and model perception of AI-generated images [C]// Proceedings of the Advances in Neural Information Processing Systems 36. New Orleans, USA. Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2023: 25435-25447.
[70] ZHU M J, CHEN H T, YAN Q Y, et al. GenImage: a million-scale benchmark for detecting AI-generated image [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2306.08571.
[71] RICKER J, DAMM S, HOLZ T, et al. Towards the detection of diffusion model deepfakes[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2210.14571.
[72] BIRD J J, LOTFI A. CIFAKE: image classification and explainable identification of AI-generated synthetic images [J]. IEEE Access, 2024, 12: 15642-15650.
[73] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16×16 words: Transformers for image recognition at scale[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2010.11929.
[74] COCCOMINI D A, ESULI A, FALCHI F, et al. Detecting images generated by diffusers[J]. PeerJ Computer Science, 2024, 10: e2127.
[75] DAS S, DUTTA D, GHOSH T, et al. Universal detection and source attribution of diffusion model generated images with high generalization and robustness [M]// MAJI P, HUANG T, PAL N R, et al. Pattern recognition and machine intelligence. Berlin, Germany: Springer, 2023: 441-448.
[76] ZHU M J, CHEN H T, HUANG M X, et al. GenDet: towards good generalizations for AI-generated image detection[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2312.08880.
[77] HE Z Y, CHEN P Y, HO T Y. RIGID: a training-free and model-agnostic framework for robust AI-generated image detection[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2405.20112.
[78] OQUAB M, DARCET T, MOUTAKANNI T, et al. DINOv2: learning robust visual features without supervision [EB/OL]. [2025-10-16]. https://arxiv.org/pdf/2304.07193.
[79] XU K, ZHANG L, SHI J. Detecting image attribution for text-to-image diffusion models in RGB and beyond [EB/OL]. [2025-10-16]. https://arxiv.org/html/2403.19653v1.
[80] YAN S L, LI O X, CAI J Y, et al. A sanity check for AI-generated image detection [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2406.19435.
[81] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2103.00020.
[82] SHA Z Y, LI Z, YU N, et al. DE-FAKE: detection and attribution of fake images generated by text-to-image generation models [C]// Proceedings of the 2023 ACM SIGSAC Conference on Computer and Communications Security. New York, USA: ACM Press, 2023: 3418-3432.
[83] LIU Z H, WANG H Y, KANG Y Y, et al. Mixture of low-rank experts for transferable AI-generated image detection [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2404.04883.
[84] HU E J, SHEN Y L, WALLIS P, et al. LoRA: low-rank adaptation of large language models[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2106.09685.
[85] KHAN S A, DANG-NGUYEN D T. CLIPping the deception: adapting vision-language models for universal deepfake detection [C]// Proceedings of the 2024 International Conference on Multimedia Retrieval. New York, USA: ACM Press, 2024: 1006-1015.
[86] COZZOLINO D, POGGI G, CORVI R, et al. Raising the bar of AI-generated image detection with CLIP[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2312.00195.
[87] GAINTSEVA T, KUSHNAREVA L, MAGAI G, et al. Improving interpretability and robustness for the detection of AI-generated images[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2406.15035.
[88] SHEN Z, ZHANG K, JIA B, et al. DF-LLaVA: unlocking MLLM's potential for synthetic image detection via prompt-guided knowledge injection [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2509.14957.
[89] CHANG Y M, YEH C, CHIU W C, et al. AntifakePrompt: prompt-tuned vision-language models are fake image detectors [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2310.17419.
[90] EUTAMENE H B, HAMIDOUCHE W, KEITA M, et al. SIREN: self-improving retrieval-augmented deepfake detection with explainable LLM reasoning[EB/OL]. [2025-10-16]. https://ssrn.com/abstract=5492126.
[91] CHEN J X, YAO J T, NIU L. A single simple patch is all you need for AI-generated image detection[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2402.01123.
[92] YUAN L, LI X, ZHANG Y, et al. MLEP: multi-granularity local entropy patterns for generalized ai-generated image detection [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2504.13726.
[93] WONG Y J, NG T K. Local statistics for generative image detection [EB/OL]. [2025-10-16]. https://arxiv.org/html/2310.16684v2.
[94] ZHANG J H, LI L, YAN C G, et al. Frequency-aware correlation discovering and spatial forgery clue distilling for synthetic image detection[C]//Proceedings of the 33rd ACM International Conference on Multimedia. New York, USA: ACM Press, 2025: 11726-11735.
[95] DAS D, YAHAN M, ZAMAN M T, et al. Edge-enhanced vision transformer framework for accurate AI-generated image detection [EB/OL]. [2025-10-16]. https://arxiv.org/abs/2508.17877.
[96] JU Y, JIA S, CAI J L, et al. GLFF: global and local feature fusion for AI-synthesized image detection[J]. IEEE Transactions on Multimedia, 2024, 26: 4073-4085.

计算机工程 www.ecice06.com

[97] UHLENBROCK L, COZZOLINO D, MOUSSA D, et al. Did you note my palette? Unveiling synthetic images through color statistics[C]//Proceedings of the 2024 ACM Workshop on Information Hiding and Multimedia Security. New York, USA: ACM Press, 2024: 47-52.

[98] DOGOULIS P, KORDOPATIS-ZILOS G, KOMPATSIARIS I, et al. Improving synthetically generated image detection in cross-concept settings[C]//Proceedings of the 2nd ACM International Workshop on Multimedia AI against Disinformation. New York, USA: ACM Press, 2023: 28-35.

[99] CHENG H, GUO Y Y, WANG T Y, et al. Diffusion facial forgery detection[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2401.15859.

[100] ZHONG N, XU Y R, LI S, et al. PatchCraft: exploring texture patch for efficient AI-generated image detection[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2311.12397.

[101] LU Y H, EBRAHIMI T. Towards the detection of AI-synthesized human face images[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2402.08750.

[102] DOLORIEL C T, CHEUNG N M. Frequency masking for universal deepfake detection[C]//Proceedings of 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Washington D. C., USA: IEEE Press, 2024: 1-10.

[103] KOUTLIS C, PAPADOPOULOS S. Leveraging representations from intermediate encoder-blocks for synthetic image detection[C]//Proceedings of the ECCV 2024. Berlin, Germany: Springer, 2025: 394-411.

[104] BARU L B, BODDEDA R, PATEL S A, et al. Wavelet-driven generalizable framework for deepfake face forgery detection[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision Workshops (WACVW). Washington D.C., USA: IEEE Press, 2025: 1576-1584.

[105] LANZINO R, FONTANA F, DIKO A, et al. Faster than lies: real-time deepfake detection using binary neural networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). Washington D.C., USA: IEEE Press, 2024: 3771-3780.

[106] KARAGEORGIOU D, PAPADOPOULOS S, KOMPATSIARIS I, et al. Any-resolution AI-generated image detection by spectral learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D. C., USA: IEEE Press, 2025: 18706-18717.

[107] ZHANG D C, ZHANG T, GE S M, et al. Enhancing frequency forgery clues for diffusion-generated image detection[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2511.00429.

[108] ZHANG D, ZHANG T, GE S, et al. Leveraging natural frequency deviation for diffusion-generated image detection [EB/OL]. [2025-10-16]. https://openreview.net/forum?id=fPBExgC1m9&referrer=%5Bthe%20profile%20of%20Sabine%20S%C3%BCsstrunk%5D%28%2Fprofile%3Fid%3D~Sabine_S%C3%BCsstrunk1%29.

[109] ZHOU C M, WANG J A, LI Y, et al. Beyond semantic features: pixel-level mapping for generalized AI-generated image detection[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2512.17350.

[110] WEN Y, KIRCHENBAUER J, GEIPING J, et al. Tree-Ring watermarks: fingerprints for diffusion images that are invisible and robust[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2305.20030.

[111] DURALL R, KEUPER M, KEUPER J. Watch your up-convolution: CNN based generative deep neural networks are failing to reproduce spectral distributions[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D. C., USA: IEEE Press, 2020: 7887-7896.

[112] CORVI R, COZZOLINO D, POGGI G, et al. Intriguing properties of synthetic images: from generative adversarial networks to diffusion models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). Washington D. C., USA: IEEE Press, 2022: 973-982.

[113] LIU H, TAN Z C, TAN C C, et al. Forgery-aware adaptive transformer for generalizable synthetic image detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D.C., USA: IEEE Press, 2024: 10770-10780.

[114] WIßMANN A, ZEILER S, NICKEL R M, et al. Whodunit: detection and attribution of synthetic images by leveraging model-specific fingerprints[C]//Proceedings of the 3rd ACM International Workshop on Multimedia AI against Disinformation. New York, USA: ACM Press, 2024: 65-72.

[115] MENG Z L, PENG B, DONG J, et al. Artifact feature purification for cross-domain detection of AI-generated images[J]. Computer Vision and Image Understanding, 2024, 247: 104078.

[116] RICKER J, LUKOVNIKOV D, FISCHER A. AEROBLADE: training-free detection of latent diffusion images using autoencoder reconstruction error[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D. C., USA: IEEE Press, 2024: 9130-9140.

[117] MA R P, DUAN J H, KONG F, et al. Exposing the fake: effective diffusion-generated images detection[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2307.06272.

[118] LUO Y P, DU J L, YAN K, et al. LaRE^2: latent reconstruction error based method for diffusion-generated image detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D.C., USA: IEEE Press, 2024: 1-15.

[119] CHU B L, XU X, WANG X, et al. FIRE: robust detection of diffusion-generated images via frequency-guided reconstruction error[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D. C., USA: IEEE Press, 2025: 12830-12839.

[120] LIANG Y, YU M, LI G, et al. Denoising trajectory biases for zero-shot ai-generated image detection[C]//Proceedings of the 39th Annual Conference on Neural Information Processing Systems. New Orleans, USA: Neural Information Processing Systems Foundation, Inc. (NeurIPS), 2025: 1-17.

[121] SINITSA S, FRIED O. Deep image fingerprint: towards low budget synthetic image detection and model lineage analysis[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). Washington D.C., USA: IEEE Press, 2024: 4055-4064.

[122] TAN C C, LIU H, ZHAO Y, et al. Rethinking the up-sampling operations in CNN-based generative network for generalizable deepfake detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D. C., USA: IEEE Press, 2024: 28130-28139.

计算机工程 www.ecice06.com

[123] CAZENAVETTE G, SUD A, LEUNG T, et al. FakeInversion: learning to detect images from unseen text-to-image models by inverting stable diffusion [C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D. C., USA: IEEE Press, 2024: 10759-10769.

[124] ZHANG Y C, XU X G. Diffusion noise feature: accurate and fast generated image detection[EB/OL]. [2025-10-16]. https://arxiv.org/abs/2312.02625.

[125] CHEN B Y, ZENG J S, YANG J Q, et al. DRCT: diffusion reconstruction contrastive training towards universal detection of diffusion generated images [C] // Proceedings of the International Conference on Machine Learning. [S. l.]: PMLR, 2024:7621-7639.

[126] CORVI R, COZZOLINO D, ZINGARINI G, et al. On the detection of synthetic images generated by diffusion models [EB/OL]. [2025-10-16]. https: // arxiv. org/abs/2211.00680.

[127] ZHANG H F, HE Q H, BI X L, et al. Towards universal AI-generated image detection by variational information bottleneck network [C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D. C., USA: IEEE Press, 2025: 23828-23837.

[128] JIA Z X, HUANG C W, ZHU Y S, et al. Secret lies in color: enhancing AI-generated images detection with color distribution analysis [C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Washington D. C., USA: IEEE Press, 2025: 13445-13454.

文字编辑 陆燕菲
栏目编辑 宋 圆

计算机工程 www.ecice06.com